

## IFT3395/6390 Fondements de l'apprentissage machine

Professeur : Pascal Vincent

### Devoir 1

- Ce devoir est à faire en équipe de 2 personnes. Assurez-vous d'avoir noté le nom de tous les coéquipiers en tête du rapport et en tête en commentaires de chacun des fichiers que vous remettrez.
- On demande, la remise d'un rapport en format électronique (.pdf). Tous les fichiers de code source que vous aurez créé ou adapté devront également être remis. La partie pratique est à faire en python (en utilisant les bibliothèques numpy et matplotlib), et vous pouvez bien entendu fortement vous inspirer de ce qui a été fait pendant les labos; certaines parties de ce devoir étant très proches de ce qui a été vu dans les labos.
- Vous pouvez remettre votre code python sous la forme d'un notebook ipython .ipynb. Pour produire un rapport avec des formules mathématiques vous pouvez utiliser le logiciel de votre choix :  $\text{\LaTeX}$ ;  $\text{\LyX}$ ; Word; voire même écrire directement les parties théoriques dans le notebook (en entrant les équations en format MathJaX pour qu'elles s'affichent). Dans tous les cas on vous demande d'exporter votre **rapport en .pdf** que vous remettrez.
- La remise doit se faire via StudiUM. **Une seule remise par équipe** (un seul des coéquipiers effectue la remise). Assurez-vous d'avoir noté le nom de tous les coéquipiers en tête du rapport. Si vous avez beaucoup de fichiers à remettre vous pouvez aussi (c'est peut-être plus pratique) en faire une archive (.zip ou .tar.gz) et téléverser le fichier d'archive.

## 1 Partie théorique : Estimation de densité

Dans cette question on considère un ensemble de données  $D = \{x^{(1)}, \dots, x^{(n)}\}$  avec  $x \in \mathbb{R}^d$ .

1. Considérons d'abord estimer la densité avec des fenêtres de Parzen à noyau Gaussien isotropique.

- (a) Écrivez l'équation du noyau correspondant à une densité Gaussienne isotropique :  $K(x; x^{(i)}) = \mathcal{N}_{x^{(i)}, \sigma^2}(x) = \dots$
  - (b) Écrivez l'équation de la densité ainsi estimée (prédite) par l'estimateur de densité de Parzen en un (nouveau) point  $x$ , en détail (formule utilisant la fonction exponentielle)
  - (c) Ce modèle (algorithme de fenêtres de Parzen) a-t-il des hyper-paramètres ? Si oui lesquels et quelles sont leurs dimensions. A-t-il des paramètres ? Si oui lesquels et quelles sont leurs dimensions.
  - (d) Démontrez que la densité ainsi estimée vérifie bien les propriétés d'une densité de probabilité.
2. Considérons maintenant plutôt une estimation de densité paramétrique avec une densité Gaussienne **isotropique**.
- (a) Écrivez (la forme de) l'équation paramétrique de la densité estimée (prédite) en un (nouveau) point  $x$ .
  - (b) Quelle est la différence la plus marquante avec l'estimation par fenêtre de Parzen ?
  - (c) Ce modèle (algorithme) a-t-il des hyper-paramètres ? Si oui lesquels et quelles sont leurs dimensions. A-t-il des paramètres ? Si oui lesquels et quelles sont leurs dimensions.
3. Considérons maintenant une estimation de densité paramétrique avec une densité Gaussienne **diagonale**.
- (a) Exprimez l'équation d'une densité Gaussienne diagonale dans  $\mathbb{R}^d$ . Et précisez ce que sont ses paramètres et leurs dimension.
  - (b) Démontrez que les *composantes* d'un vecteur aléatoire qui suit une distribution Gaussienne diagonale sont des variables aléatoires **in-dépendantes**.
  - (c) En utilisant comme coût  $-\log p(x)$  écrivez l'équation qui correspondrait à la minimisation du risque empirique sur un ensemble  $D$  (pour apprendre les paramètres)
  - (d) Résolvez cette équation de manière analytique pour obtenir les paramètres optimaux.
4. Expliquez, pour un ensemble de données  $D$ , comment vous procéderiez pour choisir la meilleure approche parmi les approches 1) 2) et 3), ainsi que pour sélectionner leurs hyper-paramètres s'il y a lieu.

## 2 Partie théorique : Classifieurs de Bayes

Dans cette question on considère un ensemble de données  $D = \{(x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)})\}$  avec  $x \in \mathbb{R}^d$  et  $y \in \{1, \dots, m\}$ . Avec  $m = 3$  (3 classes).

1. Considérons le **classifieur de Bayes** obtenu avec des **densités paramétriques Gaussiennes diagonales**.
  - (a) Nommez et donnez les dimensions de **tous** les paramètres à apprendre
  - (b) Donnez l'expression qui permettra de calculer les valeurs optimales de ces paramètres (vous pouvez utiliser directement votre résultat de 1.3.d)
  - (c) Exprimez, pour une entrée  $x$ , la probabilité prédite pour chacune des 3 classes par ce classifieur de Bayes
2. Considérons le **classifieur de Bayes** obtenu avec des **fenêtres de Parzen à noyau Gaussien isotropique**
  - (a) Ici  $\sigma$  n'est pas un paramètre, mais un hyper-paramètre. Quels paramètres du classifieur de Bayes reste-t-il à apprendre en utilisant l'ensemble d'entraînement ?
  - (b) Exprimez, pour une entrée  $x$ , la probabilité prédite pour chacune des 3 classes par ce classifieur de Bayes
3. Considérons maintenant un **classifieur de Parzen pour la classification multiclasse** à noyau Gaussien isotropique (voir notes de cours)
  - (a) Exprimez pour une entrée (observation)  $x$ , la probabilité prédite pour chacune des 3 classes par ce **classifieur de Parzen** multiclasse (voir notes de cours).
  - (b) Montrez que cette prédiction est équivalent au classifieur de Bayes construit avec des estimations de densité de Parzen à noyau Gaussien isotropique.

### 3 Partie pratique : estimation de densité

1. Implémentez un estimateur de densité paramétrique Gaussien diagonal. Il devra pouvoir fonctionner pour des données de dimension  $d$  arbitraire. Comme vu dans les labos, il devrait avoir une méthode **train** pour apprendre les paramètres et une méthode **compute\_predictions** qui calcule les  $\log$  de densité.
2. Implémentez un estimateur de densité de Parzen à noyau Gaussien isotropique. Il devra pouvoir fonctionner pour des données de dimension  $d$  arbitraire. De même il devrait avoir une méthode **train** pour apprendre les paramètres et une méthode **compute\_predictions** qui calcule les  $\log$  de densité.
3. Densités 1D : Parmi l'ensemble de données Iris, choisissez le sous-ensemble correspondant à une des classes (de votre choix), et un des traits caractéristiques, de sorte qu'on sera en dimension  $d = 1$  et produisez un unique graphique (à l'aide de la fonction `plot`) comportant :
  - (a) les points du sous-ensemble de données (affichés sur l'axe des  $x$ )
  - (b) une courbe de la densité estimée par votre estimateur paramétrique Gaussien
  - (c) une courbe de la densité estimée par l'estimateur de Parzen avec un hyper-paramètre  $\sigma$  (écart type) trop petit
  - (d) une courbe de la densité estimée par l'estimateur de Parzen avec un hyper-paramètre  $\sigma$  un peu trop grand
  - (e) une courbe de la densité estimée par l'estimateur de Parzen avec un hyper-paramètre  $\sigma$  que vous jugerez plus approprié.Utilisez une couleur différente pour chaque courbe, et munissez votre graphique d'une légende claire.
4. Densités 2D : Ajoutez maintenant un second trait caractéristique d'Iris, afin d'avoir des entrées en dimension  $d = 2$  et produisez 4 graphiques, chacun affichant les points du sous-ensemble de données (avec la fonction `plot`), et les lignes de contours de la densité estimée (à l'aide de la fonction `contour`) suivante :
  - (a) par votre estimateur paramétrique Gaussien diagonal
  - (b) par l'estimateur de Parzen avec un hyper-paramètre  $\sigma$  (écart type) trop petit

- (c) par l'estimateur de Parzen avec un hyper-paramètre  $\sigma$  un peu trop grand
- (d) par l'estimateur de Parzen avec un hyper-paramètre  $\sigma$  que vous jugerez plus approprié.

## 4 Partie pratique : classifieur de Bayes

1. Mélangez les exemples de Iris ( utilisez `numpy.random.shuffle` après avoir initialisé le générateur aléatoire comme suit `numpy.random.seed(123)` ). Puis divisez l'ensemble de tous les exemples en 2 : un ensemble d'entraînement, et un ensemble de validation. Préparez deux versions de chacun de ces ensembles : une version complète comportant les  $d = 4$  traits caractéristiques. Et une version avec seulement les  $d = 2$  premiers traits caractéristiques qu'on utilisera pour fins de visualisation.
2. **Classifieur de Bayes basé sur des densités paramétriques Gaussiennes diagonales**
  - (a) Implémentez l'algorithme de classifieur de Bayes basé sur des densités paramétriques Gaussiennes diagonales
  - (b) Visualisation en dimension  $d = 2$ . Considérant seulement les deux premiers traits caractéristiques d'iris, entraînez votre classifieur de Bayes sur votre ensemble d'entraînement ; affichez un graphique avec les régions de décision obtenues (ainsi que les points des ensembles d'entraînement et de validation).
  - (c) Calcul des erreurs en dimension  $d = 2$  : calculez et affichez le taux d'erreur de votre classifieur (entraîné sur les 2 premiers traits caractéristiques), à la fois sur l'ensemble d'entraînement et de validation.
  - (d) Calcul des erreurs en dimension  $d = 4$  : Entraînez votre classifieur en utilisant tous les traits caractéristiques. Puis calculez et affichez le taux d'erreur de votre classifieur (entraîné sur tous les traits caractéristiques), à la fois sur l'ensemble d'entraînement et de validation.
3. **Classifieur de Bayes basé sur des densités de Parzen avec noyau Gaussien isotropique**

- (a) Implémentez l'algorithme de classifieur de Bayes basé sur des densités de Parzen avec noyau Gaussien isotropique
  - (b) Visualisation en dimension  $d = 2$ . Considérant seulement les deux premiers traits caractéristiques d'iris, entraînez votre classifieur de Bayes sur votre ensemble d'entraînement ; affichez un graphique avec les régions (surface) de décision obtenues (ainsi que les points des ensembles d'entraînement et de validation). Produisez 3 tels graphiques de régions de décision : un avec un  $\sigma$  trop petit, trop grand, et approprié
  - (c) Courbes d'apprentissage avec  $d = 2$ . Calculez le taux d'erreur de classification, à la fois sur l'ensemble d'entraînement, et sur l'ensemble de validation, en fonction des valeurs de l'hyper-paramètre  $\sigma$  (calculez-les pour une centaine de valeurs différentes de cet hyper-paramètre afin de pouvoir afficher la courbe). Indiquez la meilleure valeur de l'hyper-paramètre  $\sigma$  que vous avez trouvé.
  - (d) Courbes d'apprentissage avec  $d = 4$ . On va maintenant utiliser tous les traits caractéristiques. Calculez le taux d'erreur de classification, à la fois sur l'ensemble d'entraînement, et sur l'ensemble de validation, en fonction des valeurs de l'hyper-paramètre  $\sigma$  (calculez-les pour une centaine de valeurs différentes de cet hyper-paramètre afin de pouvoir afficher la courbe). Indiquez la meilleure valeur de l'hyper-paramètre  $\sigma$  que vous avez trouvé.
4. D'après ces expériences, pour le problème de classification d'Iris (et pour cette division entraînement/validation particulière) indiquez quel est le meilleur choix d'algorithme entre classifieur de Bayes avec Gaussiennes diagonales, et fenêtres de Parzen, et des autres hyper-paramètres : dimension de l'entrée (2 ou 4), et  $\sigma$  (s'il y a lieu). Précisez les taux d'erreurs de classification qu'ils permettent d'atteindre.